

Patrones de viento y su impacto en la incidencia de infecciones respiratorias agudas en Panamá

Wind patterns and their impact on the incidence of acute respiratory infections in Panama

Fabiola M. Montero-González^{1,2} , Luis A. Muñoz-Morales¹ , Samuel A. Rodríguez-Rodríguez,^{1,3} , Antonio Melillo-Acevedo¹ , Juan Castillo^{1*} 

¹ Facultad de Ingeniería Industrial, Universidad Tecnológica de Panamá, Panamá

² Universidad de Panamá, Facultad de Informática, Electrónica y Comunicación, Departamento de Informática, Panamá

³ Universidad de Panamá, Facultad de Ciencias Naturales, Exactas y Tecnología, Escuela de Estadística, Panamá

*Autor de correspondencia: juan.castillo21@utp.ac.pa

RESUMEN. En Panamá, las infecciones respiratorias agudas (IRA) representan una importante carga para la salud pública pero su relación con las condiciones del viento ha sido poco explorada. Este estudio tuvo como objetivo identificar correlaciones entre los patrones de viento y la incidencia de IRA en Panamá durante el periodo 2017-2021, mediante la integración de datos meteorológicos y epidemiológicos. Se completaron datos epidemiológicos oficiales de casos de infecciones respiratorias con registros de variables de viento y otros parámetros meteorológicos provenientes de la plataforma ERA5, abarcando todo el territorio nacional. La información fue depurada y validada en Python, y posteriormente se aplicaron modelos de regresión geográficamente ponderada (GWR), multiescala (MGWR), KhanZulfiqar y modelos aditivos generalizados espacio-temporales (ST-GAM), complementados con un panel interactivo en Power BI. Los resultados mostraron que la velocidad y dirección del viento, junto con el índice Caribbean Low Level Jet, se correlacionan de manera significativa con la variabilidad geográfica y temporal de los casos, evidenciando heterogeneidad espacial y patrones estacionales consistentes. Se observó que la integración de las dimensiones espacial y temporal mejoró la capacidad predictiva de los modelos, alcanzando altos niveles de interpretabilidad y baja incertidumbre. Se desarrolló además un panel de visualización que facilita la exploración de escenarios y la generación de alertas tempranas. En conclusión, el estudio demuestra que los patrones de viento, en conjunto con la humedad relativa, presión atmosférica, son un factor determinante en la dinámica de las infecciones respiratorias agudas en Panamá. Esto respalda su incorporación en los sistemas de vigilancia epidemiológica y en la planificación de intervenciones preventivas.

Palabras clave. *Análisis de datos, enfermedades respiratorias, epidemiología, Panamá, viento.*

ABSTRACT. In Panama, acute respiratory infections (ARI) represent a major public health burden, but their relationship with wind conditions has been little explored. This study aimed to identify correlations between wind patterns and the incidence of ARI in Panama during the 2017–2021 period by integrating meteorological and epidemiological data. Official epidemiological records of ARI cases were combined with wind variables and other meteorological parameters from the ERA5 platform, covering the entire national territory. The data were cleaned and validated in Python, and geographically weighted regression (GWR), multiscale GWR (MGWR), KhanZulfiqar, and spatiotemporal generalized additive models (ST-GAM) were applied, complemented by an interactive dashboard in Power BI. The results showed that wind speed and direction, together with the Caribbean Low Level Jet (CLLJ) index, are significantly correlated with the geographic and temporal variability of ARI cases, revealing spatial heterogeneity and consistent seasonal patterns. Integrating spatial and temporal dimensions improved the predictive capacity of the models, achieving high interpretability values and low uncertainty. In addition, a visualization dashboard was developed to facilitate scenario exploration

Citación: F. Montero, L. Muñoz, S. Rodríguez, A. Melillo y J. Castillo, “Patrones de viento y su impacto en la incidencia de infecciones respiratorias agudas en Panamá”, *Revista de I+D Tecnológico*, vol. 21, no. 1, pp. (0), 2025.

Tipo de artículo: No_modificar. **Recibido:** No_modificar. **Recibido con correcciones:** No_modificar. **Aceptado:** No_modificar.

DOI.

Copyright: 2025 F. Montero, L. Muñoz, S. Rodríguez, A. Melillo y J. Castillo. This is an open access article under the CC BY-NC-SA 4.0 license (<https://creativecommons.org/licenses/by-nc-sa/4.0/>).

and the generation of early warnings. In conclusion, the study demonstrates that wind patterns are a key factor in the dynamics of acute respiratory infections in Panama and supports their incorporation into epidemiological surveillance systems and the planning of preventive interventions.

Keywords. *Data analysis, respiratory diseases, epidemiology, Panama, wind.*

1. INTRODUCCIÓN

Las infecciones respiratorias agudas (IRA) representan una de las principales causas de morbilidad en Panamá y generan una alta demanda de servicios en el sistema de salud. Diversos estudios han demostrado que factores meteorológicos como la precipitación y la humedad influyen en la estacionalidad de estas enfermedades. Sin embargo, el viento —un componente fundamental del sistema climático— ha sido menos investigado, a pesar de su capacidad para transportar y dispersar partículas, contaminantes y patógenos, lo que lo convierte en un factor determinante en la aparición y propagación de infecciones respiratorias. Fenómenos como la baja humedad relativa y las corrientes de aire seco han sido vinculados con el incremento de asma, bronquitis y enfermedad pulmonar obstructiva crónica (EPOC), afectando principalmente a niños, adultos mayores y personas con defensas inmunológicas comprometidas.

1.1 Naturaleza del problema y relevancia

Las condiciones de viento seco (humedad relativa < 40%) deterioran las defensas de las vías respiratorias, incrementan la inflamación y favorecen infecciones [1]. Las intrusiones de la Capa de Aire Sahariano (SAL) transportan polvo y aerosoles que reducen la calidad del aire y desencadenan crisis respiratorias [2], [3]. Durante la temporada seca (enero–abril), los vientos alisios pueden transportar aire más seco desde el Atlántico hacia el istmo panameño, aumentando la exposición a partículas en suspensión [4]. A nivel fisiológico, la baja humedad reseca las mucosas y reduce la defensa antiviral innata [5], mientras que ambientes fríos y secos favorecen la estabilidad y transmisibilidad de virus respiratorios [6]; varios estudios observacionales han asociado estos ambientes con mayor incidencia de infecciones respiratorias [7], [8], [9].

1.2 Fundamentos climáticos y de dispersión

En el Caribe y Panamá destacan los vientos de bajo nivel, donde el Caribbean Low-Level Jet (CLLJ) domina alrededor de 925 hPa y se asocia a una relación inversa con la precipitación (picos típicos en julio y febrero) [10]. De forma complementaria, el Panama Low-Level Jet (PLLJ) presenta variabilidad anual e interanual, influida por la zona de convergencia intertropical (ZCIT) y por el fenómeno de El Niño-Oscilación del Sur (ENSO), con intensificación en la estación seca (diciembre–abril) [11]. La capa límite atmosférica —que varía diurnamente entre ~300 y 1200 m— modula la concentración de contaminantes: cuando es baja, los contaminantes quedan atrapados cerca del suelo [12]. Asimismo, el viento controla tanto la dispersión como la resuspensión de partículas; a velocidades elevadas puede levantar material particulado clasificado como PM₁₀ y PM_{2.5}, con implicaciones para el sistema respiratorio y cardiovascular [13], [14].

1.3 Efectos fisiológicos y evidencia clínica

En asma, la inhalación de aire frío y seco provoca broncoespasmos (contracción repentina de los músculos de los bronquios) a través de varios mecanismos. Por un lado, se producen cambios osmóticos, es decir, movimientos de agua que alteran el equilibrio de líquidos en las vías respiratorias: al entrar aire muy seco, el agua del moco recubre la tráquea y los bronquios y tiende a evaporarse, lo que concentra las sales y aumenta la irritación. Por otro lado, se dan pérdidas evaporativas, que consisten en la salida de vapor de agua desde la superficie de las mucosas, enfriándolas y reseándolas. La influencia del aire seco suele ser mayor que la del aire frío en la aparición de crisis asmáticas [15].

En población pediátrica, las tormentas de polvo se han asociado con aumentos de consultas respiratorias

estacionales [16], aunque existen contextos regionales donde se observan patrones diferentes, lo que subraya la importancia del análisis local [17]. En EPOC y bronquitis, la baja humedad afecta el aclaramiento mucociliar, el sistema natural de limpieza de las vías respiratorias. Este mecanismo depende de una fina capa periciliar, una película de líquido que permite que los cilios, estructuras microscópicas en forma de pelitos que recubren la tráquea y los bronquios, se muevan de manera coordinada para expulsar moco con polvo, patógenos y contaminantes. Cuando el aire es demasiado seco, la capa periciliar se adelgaza y aumenta la viscosidad del moco, lo que altera el batido ciliar (movimiento rítmico de los cilios), frenando la expulsión de partículas y gérmenes [18], [19].

Estas alteraciones favorecen la acumulación de secreciones y aumentan la resistencia al flujo de aire dentro de los pulmones. Además, pueden desencadenar atelectasias, es decir, el colapso parcial o total de los alvéolos, las diminutas cavidades pulmonares donde se realiza el intercambio de oxígeno [20]. En conjunto, estos procesos incrementan la susceptibilidad a infecciones respiratorias y agravan las enfermedades crónicas ya existentes.

1.4 Estado del arte internacional y regional

En el Caribe, se han documentado aumentos de hospitalizaciones por asma y otras infecciones respiratorias durante episodios de polvo sahariano en Trinidad y Tobago [21], Guadalupe [22] y Granada [23]. En Norteamérica, estudios en Miami [24] mostraron exacerbaciones de EPOC durante intrusiones de polvo, mientras que en Europa se han descrito aumentos de urgencias pediátricas en Murcia (España) relacionados con partículas PM_{10} (material particulado con diámetro $\leq 10 \mu m$), O_3 (ozono troposférico) y NO_2 (dióxido de nitrógeno) [25]. En América Latina, investigaciones en Quito [26] y Bogotá [27] han utilizado modelos espaciales y de aprendizaje automático para predecir brotes integrando variables de calidad del aire, humedad y viento. En Panamá, un estudio pionero demostró asociaciones entre PM_{10} , O_3 y NO_2 y mayor mortalidad cardiovascular y respiratoria, sin evaluar el rol directo del

viento, lo que evidencia una importante brecha de conocimiento [28].

Además de la evidencia epidemiológica, se han desarrollado indicadores biometeorológicos que combinan temperatura, humedad y viento, ofreciendo herramientas complementarias para anticipar brotes de enfermedades respiratorias. En Polonia, el índice Humidex, que combina temperatura y humedad relativa, mostró una fuerte correlación con las hospitalizaciones por asma y EPOC durante los meses de verano, lo que confirma su valor como predictor de crisis respiratorias asociadas al estrés térmico [29]. En Grecia, el análisis de patrones de viento en la isla de Creta reveló que los vientos del sur y suroeste, asociados al transporte de polvo sahariano, incrementan las admisiones pediátricas por asma y rinitis, mientras que los vientos del norte se relacionan con bronquiolitis y neumonía [30]. Estudios de dinámica de fluidos computacional en hospitales y aulas propusieron nuevos indicadores de ventilación — Air Utilization Effectiveness (AUE) y Contaminant Dispersion Index (CDI)— que mostraron una correlación muy alta con el riesgo de infección transmitida por el aire, superando en precisión a los índices tradicionales [31].

En China, se han validado dos indicadores que han demostrado gran precisión. El Wind Chill Index (WCI), que combina temperatura y velocidad del viento, se asoció significativamente con hospitalizaciones por exacerbación de EPOC en el distrito de Fengxian, Shanghai [32]. Por su parte, la Net Effective Temperature (NET), que integra temperatura, humedad y viento, permitió predecir ingresos pediátricos por enfermedades respiratorias [33].

1.5 Objetivo, contribución y alcance

Este estudio tiene como objetivo identificar correlaciones relevantes entre los patrones de viento y la incidencia de infecciones respiratorias agudas (IRA) en Panamá durante el período 2017-2021, mediante la integración de datos meteorológicos y epidemiológicos.

La contribución del estudio radica en: proponer un marco analítico que vincula la dinámica de los jets de

bajo nivel del Caribe (CLLJ) y de Panamá (PLLJ) con los procesos de dispersión y transmisión de patógenos; aplicar modelos predictivos y causales capaces de capturar la heterogeneidad espacial y temporal de la relación entre variables meteorológicas y casos de IRA; y desarrollar un panel interactivo de visualización que facilita la exploración de datos, la interpretación de patrones y como apoyo a alertas tempranas en salud pública.

En cuanto a su alcance, este trabajo amplía el conocimiento existente al incorporar el viento como variable clave en el análisis epidemiológico, ofreciendo herramientas para fortalecer la vigilancia sanitaria y apoyar la toma de decisiones preventivas.

La estructura del artículo es la siguiente: la sección 2 detalla materiales y métodos incluyendo fuentes de datos, preprocesamiento, variables y enfoque analítico; la sección 3 presenta los resultados, discute los hallazgos y muestra algunas de las visualizaciones del panel interactivo; finalmente, la sección 4 expone las conclusiones y las proyecciones para futuras investigaciones.

2. MATERIALES Y MÉTODOS

Para alcanzar el objetivo de analizar la influencia de los patrones de viento en la incidencia de infecciones respiratorias agudas (IRA) en Panamá durante el período 2017–2021, se diseñó una metodología de carácter observacional basada en el análisis de series temporales. Esta sección describe las fuentes de datos empleadas, las técnicas de preprocesamiento y depuración de la información, así como los procedimientos estadísticos y de modelado propuestos. La estrategia metodológica integra registros epidemiológicos y meteorológicos con la variabilidad de los casos de IRA, y sienta las bases para la construcción de modelos predictivos orientados a la salud pública.

2.1. Tipos de estudio y diseño

Estudio observacional y de análisis de series temporales. Se integran datos meteorológicos y epidemiológicos para explorar correlaciones entre los

patrones de viento y los casos de IRA en Panamá durante el período 2017–2021.

2.2. Fuente de datos

- **Datos epidemiológicos:** Casos reportados de enfermedades respiratorias en la República de Panamá, según tipo, provincia y comarca indígena y tasa por cada 100,000 habitantes publicado por el Instituto Nacional de Estadística y Censo (INEC) de Panamá [34] y recopilado por la Sección de Estadísticas de Vigilancia, del Departamento de Epidemiología del Ministerio de Salud y obtenidos de los Anuarios de Estadísticas de Salud del Ministerio de Salud (MINSAL) [35].
- **Datos meteorológicos:** Registros de velocidad y dirección del viento, componentes u y v, humedad relativa, temperatura, presión atmosférica al nivel del mar procedentes del reanálisis ERA5 del programa Copernicus [36], [37].

2.3. Preprocesamiento de datos

El cuadro de casos reportados de enfermedades respiratorias fue normalizado en Excel para estructurarlo en columnas (Provincia, Enfermedad, Casos, Tasa, Año). Posteriormente se validó y depuró en Python empleando librerías como pandas para garantizar la consistencia y la integridad de los datos.

En el caso de la información meteorológica, se configuró un dataset derivado del reanálisis ERA5 que comprende 1,960 registros mensuales de todas las provincias de Panamá en el período 2014–2021. Cada registro contiene variables clave para el estudio de la dinámica del viento, entre ellas:

- **Componentes del viento:** `u10_media` y `v10_media` (componentes zonal y meridional a 10 m), junto con `velocidad_viento` y `direccion_viento`. Estos últimos atributos fueron calculados mediante la trigonometría a partir de los componentes.
- **Condiciones atmosféricas:** `t2m_media` (temperatura media a 2 m), `mslp_media` (presión a nivel del mar), `rel_hum_media` (humedad relativa) y `spec_hum_media` (humedad específica).

- **Índices e indicadores dinámicos:** CLLJ_index (intensidad del Chorro de Bajo Nivel del Caribe o Caribbean Low-Level Jet), ind_vent_atm (índice de ventilación atmosférica) y blh_media (altura de la capa límite).
- **Metadatos espaciales y temporales:** provincia, provincia homologada, fecha, año, mes y coordenadas geográficas (coord_x, coord_y). Estas últimas se mantuvieron en el sistema de referencia UTM (Universal Transverse Mercator) con el fin de facilitar el cálculo de distancias en los modelos matemáticos.
- **Campos de calidad de datos:** Outlier (detección de valores atípicos) y ventilacion_categoria (clasificación cualitativa de la ventilación atmosférica: Muy Pobre, Pobre, Marginal, Buena). Para la categorización de la ventilación atmosférica se empleó la escala diseñada por el

El preprocesamiento incluyó la validación de valores nulos, la validación de outliers y el cálculo de variables derivadas, asegurando una estructura uniforme y confiable para el análisis estadístico.

2.4. Variables y análisis

Para explorar la relación entre los patrones de viento y la incidencia de IRA, se definieron cuidadosamente las variables de estudio a partir del dataset meteorológico y de los registros epidemiológicos. Estas variables permiten capturar tanto la variabilidad espacial como la dinámica temporal necesarias para el análisis estadístico y el modelado predictivo.

- **Variables independientes (x) son:** temperatura media a 2 m (t2m_media), presión a nivel del mar (mslp_media), índice de intensidad del Caribbean Low Level Jet (CLLJ_index), humedad relativa media (rel_hum_media), velocidad y dirección del viento (velocidad_viento, direccion_viento), índice de ventilación atmosférica (ind_vent_atm), coordenadas geográficas (coord_x, coord_y), fecha ordinal normalizada (fecha_ordinal_norm) y mes (mes).

- **Variable dependiente (y) es:** casos_mensuales - número de casos de IRA.

Con el conjunto de datos, se llevaron a cabo las siguientes etapas de análisis:

- Configuración de un modelo explicativo espaciotemporal para evaluar interacciones entre las variables independientes y dependiente.
- Modelo predictivo para estimar el rol del viento y demás variables meteorológicas y espaciotemporales como factores causantes de casos de IRA.

2.5. Alcance y limitaciones

El estudio abarca la República de Panamá. Se excluyen predicciones a largo plazo sobre cambios permanentes en los patrones de viento y la modelización específica de la dispersión de contaminantes, debido a limitaciones en la disponibilidad de datos de calidad del aire.

2.6. Panel de visualización y análisis predictivo

Como parte de los objetivos específicos del estudio, se desarrolló un dashboard o panel interactivo de visualización en Power BI destinado a mostrar el análisis descriptivo de los patrones de viento y los casos de infecciones respiratorias. Igualmente se presentan los resultados de los modelos explicativo y predictivo seleccionados, así como una estimación del impacto económico de las IRA en Panamá. Este panel combina gráficos dinámicos, mapas georreferenciados y series temporales, lo que facilita la interpretación de tendencias, correlaciones y variaciones en el tiempo y espacio. Los gráficos y mapas más representativos de esta herramienta se presentan en la sección de resultados.

Para evaluar el papel del viento como factor epidemiológico, se aplicaron modelos predictivos y causales que integran técnicas de regresión espacial local y modelado espaciotemporal no lineal, incorporando el índice Caribbean Low Level Jet (CLLJ) tanto en su forma original como en versiones transformadas. En conjunto, estos enfoques permitieron capturar la heterogeneidad

espacial y temporal de la relación entre los patrones de viento y la transmisión de las infecciones respiratorias, cuyos principales hallazgos se detallan en la sección de resultados.

A continuación, se describen los principales modelos aplicados:

1. Regresión Geográficamente Ponderada (GWR) con índice CLLJ original

Modelo de regresión espacial local que estima coeficientes que varían geográficamente para analizar cómo las variables independientes inciden en las cantidades de casos de IRA de cada ubicación [38], [39]. En la ecuación (1) se expresa el modelo:

$$y_i = \beta_0(u_i, v_i) + \sum \beta_k(u_i, v_i) \times x_{ki} + \varepsilon_i \quad (1)$$

Donde y_i es la variable epidemiológica en la ubicación i ; (u_i, v_i) son las coordenadas geográficas; y $w_{ij} = K(d_{ij}/b)$ es la función de peso basada en la distancia.

2. Regresión Geográficamente Ponderada Multiescala (MGWR) con índice CLLJ original

Extiende la GWR al permitir que cada variable predictora actúe a su propia escala espacial óptima, determinada por un ancho de banda específico para cada coeficiente. Este ancho de banda define el tamaño de la zona de influencia utilizada para estimar la relación local entre las variables [40]. En la ecuación (2) se expresa el modelo:

$$y_i = \beta_0(u_i, v_i) + \sum \beta_k(u_i, v_i; b_k) \times x_{ki} + \varepsilon_i \quad (2)$$

Donde β_k representa el ancho de banda específico para cada variable k , optimizado independientemente.

3. GWR con índice CLLJ transformado

Emplea la transformación matemática Yeo-Johnson del índice CLLJ para mejorar propiedades estadísticas como normalidad, linealidad o homocedasticidad [41]. Se usó esta transformación debido a que el índice puede

tener valores negativos. Su fundamento estadístico se expresa en la ecuación (3):

$$y_i = \beta_0(u_i, v_i) + \beta_1(u_i, v_i) \times T(CLLJ_i) + \varepsilon_i \quad (3)$$

Donde $T(CLLJ_i)$ es la transformación aplicada al índice.

4. Modelo KhanZulfiqar

Enfoque de análisis espaciotemporal desarrollado por los investigadores Khan y Zulfiqar para el modelado epidemiológico, que se centra en la dinámica espaciotemporal de las enfermedades [42].

5. Modelos Aditivos Generalizados Espaciotemporales (ST-GAM)

Extiende los GAM tradicionales incorporando efectos suaves espaciales y temporales para capturar patrones complejos no lineales en datos epidemiológicos [43]. Su fundamento matemático se expresa en la ecuación (4):

$$g(\mu_i) = \beta_0 + s_1(x_{1i}) + s_2(x_{2i}) + f(s_i, t_i) + \varepsilon_i \quad (4)$$

Donde $g(\mu_i)$ es la función de enlace; $s_1()$, $s_2()$ son funciones suavizadas; $f(s_i, t_i)$ representa la función suavizada espaciotemporal; s_i las coordenadas espaciales y t_i es el tiempo. Se utilizaron los parámetros por omisión que tiene el lenguaje Python. Los modelos ST-GAM tienen básicamente dos parámetros que pueden ser modificados: λ que controla la suavización de las funciones y el rango (rank), que determina cuántos segmentos de curvas suavizadas se emplean para representar cada función.

6. Modelo ST-GAM con λ automático

Es una implementación de ST-GAM que ajusta los parámetros de suavizado (λ) de manera automática mediante criterios de validación cruzada o máxima verosimilitud restringida (REML) [44]. Su algoritmo de optimización se expresa en la ecuación (5):

$$\lambda^* = \underset{\lambda}{\operatorname{argmin}} [Criterio(\lambda)] \quad (5)$$

Donde el criterio puede ser:

- $GCV(\lambda) = n\|y - S\lambda y\|^2 / [\text{tr}(I - S\lambda)]^2$
- $REML(\lambda) = -2\log L_R(\lambda)$

En este caso se usó una función del lenguaje Python que optimiza los valores de los parámetros de suavización.

7. Modelo ST-GAM con λ manual

Es una implementación de ST-GAM en la que los parámetros de suavizado se fijan de forma manual a partir de conocimiento del dominio, análisis exploratorio o consideraciones teóricas [45]. Por ensayo y error se asignaron valores a los parámetros λ y rank con el fin de eliminar sobreajustes en las función.

3. RESULTADOS Y DISCUSIÓN

Resultados

3.1. Panel de Visualización

Se desarrolló un panel de visualización en Power BI para explorar de manera interactiva la relación entre las variables meteorológicas y los casos de infecciones respiratorias agudas (IRAs) en Panamá.

El dashboard integra mapas dinámicos, gráficos de correlación y series de tiempo, lo que facilita examinar la distribución geográfica de los casos, los patrones de viento y las predicciones derivadas de los modelos. Entre sus funcionalidades clave destacan los filtros por año, provincia y tipo de enfermedad, que permiten realizar análisis específicos y apoyar la toma de decisiones en salud pública, la planificación de recursos médicos y la generación de alertas tempranas.

La información se presenta en cuatro vistas complementarias:

La figura 1 muestra la tendencia de casos totales y tasas de incidencia por cada 100 000 habitantes, desagregada por tipo de enfermedad (neumonía, influenza, combinaciones con COVID-19, etc.). Esta vista permite identificar los periodos de mayor incidencia, los cambios anuales y las variaciones entre patologías.

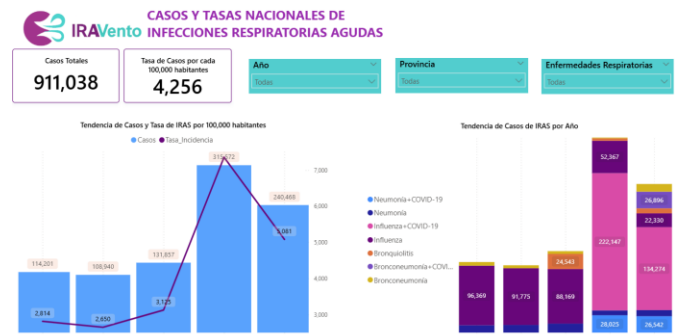


Figura 1. Casos y tasas nacionales de IRAs.

La figura 2 integra un mapa temático y gráficos comparativos que facilitan detectar las provincias con mayor carga de enfermedad, comparar tasas de incidencia y visualizar la participación porcentual de cada territorio en el total de casos.

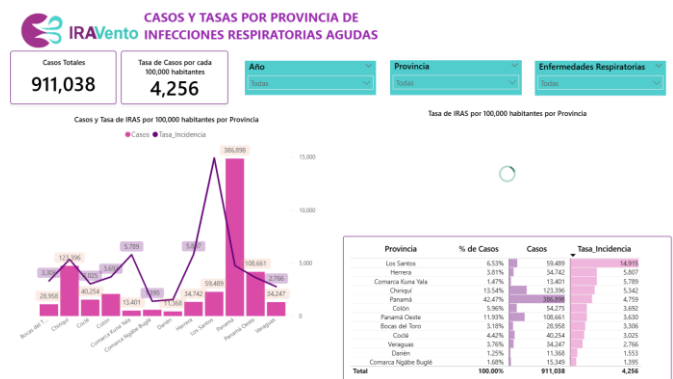


Figura 2. Distribución provincial de casos y tasas.

La figura 3 relaciona los casos de IRAs con el porcentaje de población afectada y la densidad de población. Incluye gráficos que vinculan el porcentaje de personas afectadas con la población económicamente activa, permitiendo evaluar la vulnerabilidad de distintos grupos sociales.

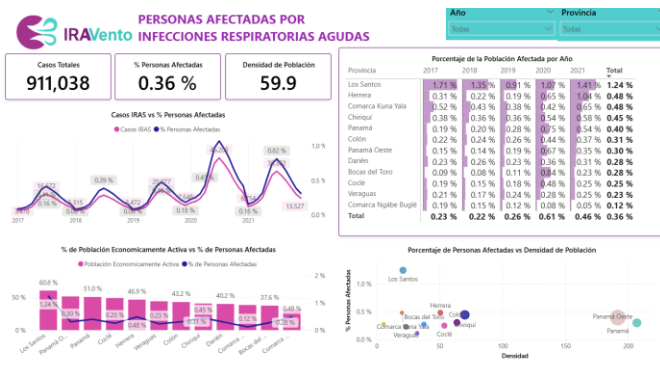


Figura 3. Personas afectadas y variables sociodemográficas.

La figura 4 presenta la evolución conjunta de la velocidad del viento y del índice de ventilación atmosférica, así como su relación con la tasa de IRAs por provincia. Esta sección es clave para examinar la correlación temporal entre las variaciones del viento y los picos de incidencia.

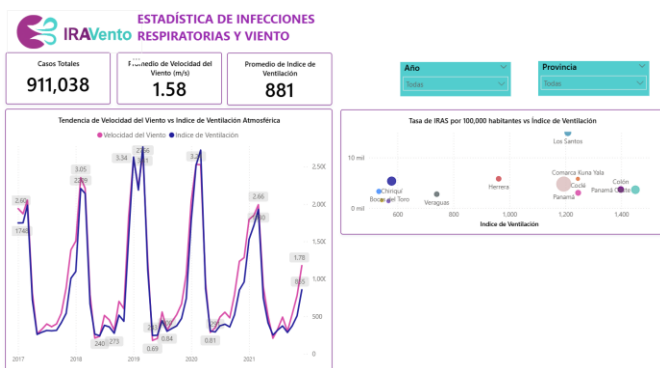


Figura 4. Estadística de infecciones respiratorias y viento.

Estas visualizaciones fortalecen el análisis descriptivo, ofreciendo una comprensión inmediata de la magnitud, distribución y determinantes de las IRAs. Además, constituyen una herramienta de apoyo para autoridades sanitarias, investigadores y ciudadanía, al permitir la evaluación de escenarios, la planificación de recursos y la comunicación de resultados de forma clara e interactiva.

3.2. Modelos explicativos

Se evaluaron varios enfoques estadísticos y de aprendizaje de máquina para explicar la relación entre los patrones de viento y la incidencia de infecciones respiratorias agudas (IRAs) en Panamá.

Modelos de regresión lineal espacio-temporal

1. Regresión Geográficamente Ponderada (GWR) con índice CLLJ en su versión original.

Este modelo permitió identificar la variabilidad espacial en relación entre las variables meteorológicas (velocidad del viento, dirección del viento, humedad relativa, temperatura, presión atmosférica, índice de ventilación atmosférica, e índice CLLJ) y los casos de IRAs.

En la figura 5 se observa que la intensidad de la relación no es uniforme en el territorio panameño. Destacan provincias del Caribe y de la franja oriental, donde los coeficientes locales alcanzan los valores más elevados, lo que indica una correlación positiva más intensa entre las dinámicas del viento y la incidencia de IRAs. En contraste, las provincias del Pacífico y el centro del país presentan correlaciones más débiles.

Estos resultados sugieren que las corrientes provenientes del Caribe, moduladas por el CLLJ, ejercen una influencia diferenciada en la dispersión de partículas y microorganismos, favoreciendo la transmisión de patógenos respiratorios en las zonas de mayor exposición. Además, el mapa de R^2 local confirma que el modelo explica un mayor porcentaje de la variabilidad en estas regiones, reforzando la solidez del patrón espacial detectado.

El análisis GWR demuestra que la relación viento–IRA es espacialmente heterogénea, lo que respalda la necesidad de estrategias de vigilancia y prevención con enfoque territorial, priorizando las áreas donde la influencia del viento es más significativa.

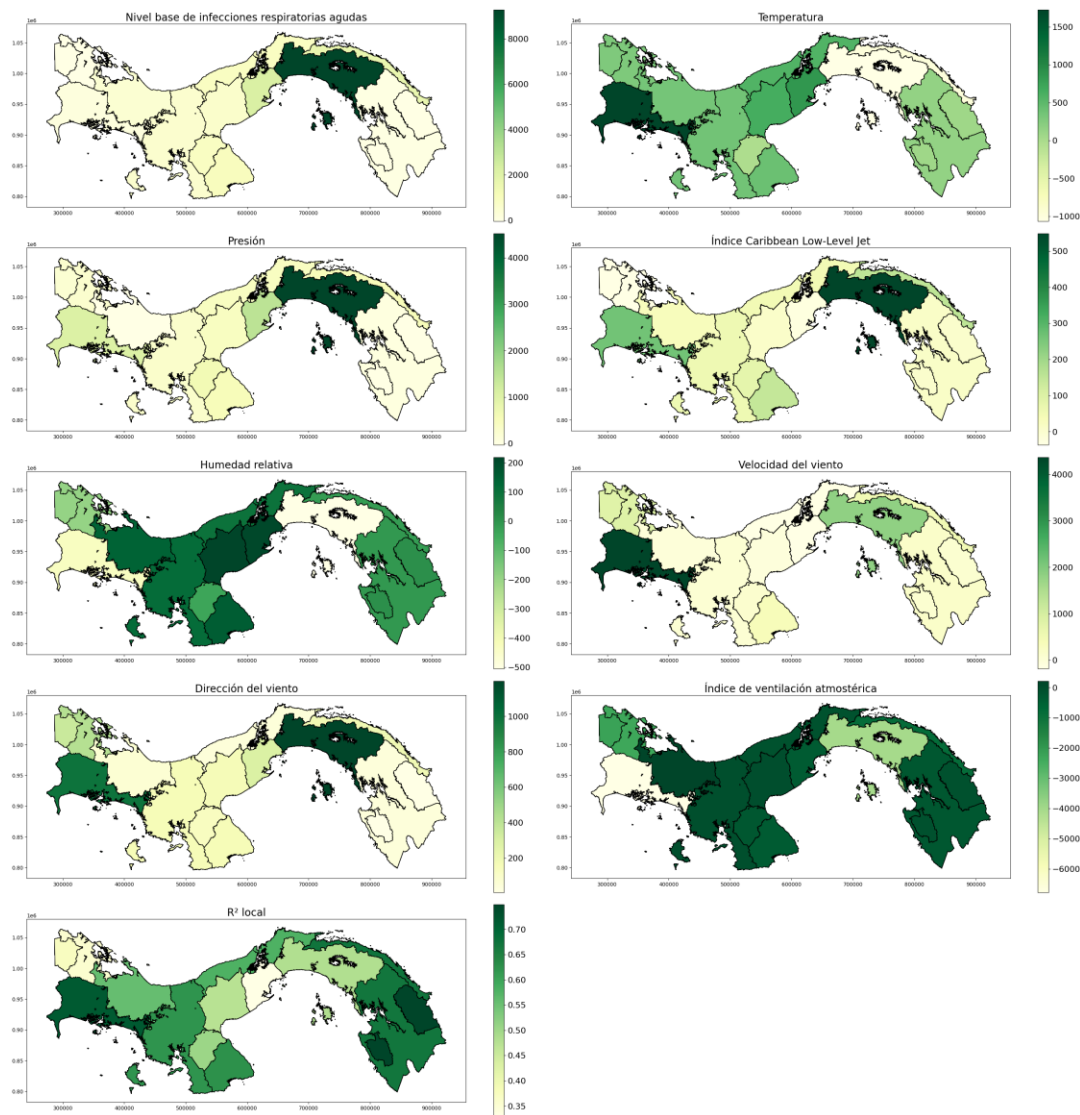


Figura 5. Mapa de coeficientes locales del modelo GWR

2. Regresión Geográficamente Ponderada Multiescala (MGWR) también con el índice CLLJ original.

Este modelo amplía el enfoque de la GWR al permitir que cada variable explicativa actúe a su propia escala espacial óptima. Esta característica posibilita captar relaciones locales más finas entre los patrones de viento y la incidencia de infecciones respiratorias agudas (IRAs).

En la figura 6 se evidencia que el grado de asociación varía de forma aún más matizada que en el modelo GWR. Se distinguen provincias donde la influencia del índice Caribbean Low Level Jet (CLLJ), la velocidad y la dirección del viento se manifiestan con mayor detalle, revelando micro-zonas de alta correlación que no se aprecian con la resolución del modelo anterior.

Este refinamiento confirma la heterogeneidad espacial de la relación viento–IRA: mientras algunas provincias del Caribe y de la vertiente oriental mantienen correlaciones positivas destacadas, otras muestran variaciones internas que reflejan la interacción de factores topográficos, microclimáticos y de urbanización.

El análisis MGWR profundiza y valida los hallazgos del GWR, demostrando que la dinámica de las IRAs en Panamá responde a múltiples escalas de influencia del viento, lo que refuerza la pertinencia de estrategias de salud pública diferenciadas por región y características climáticas.

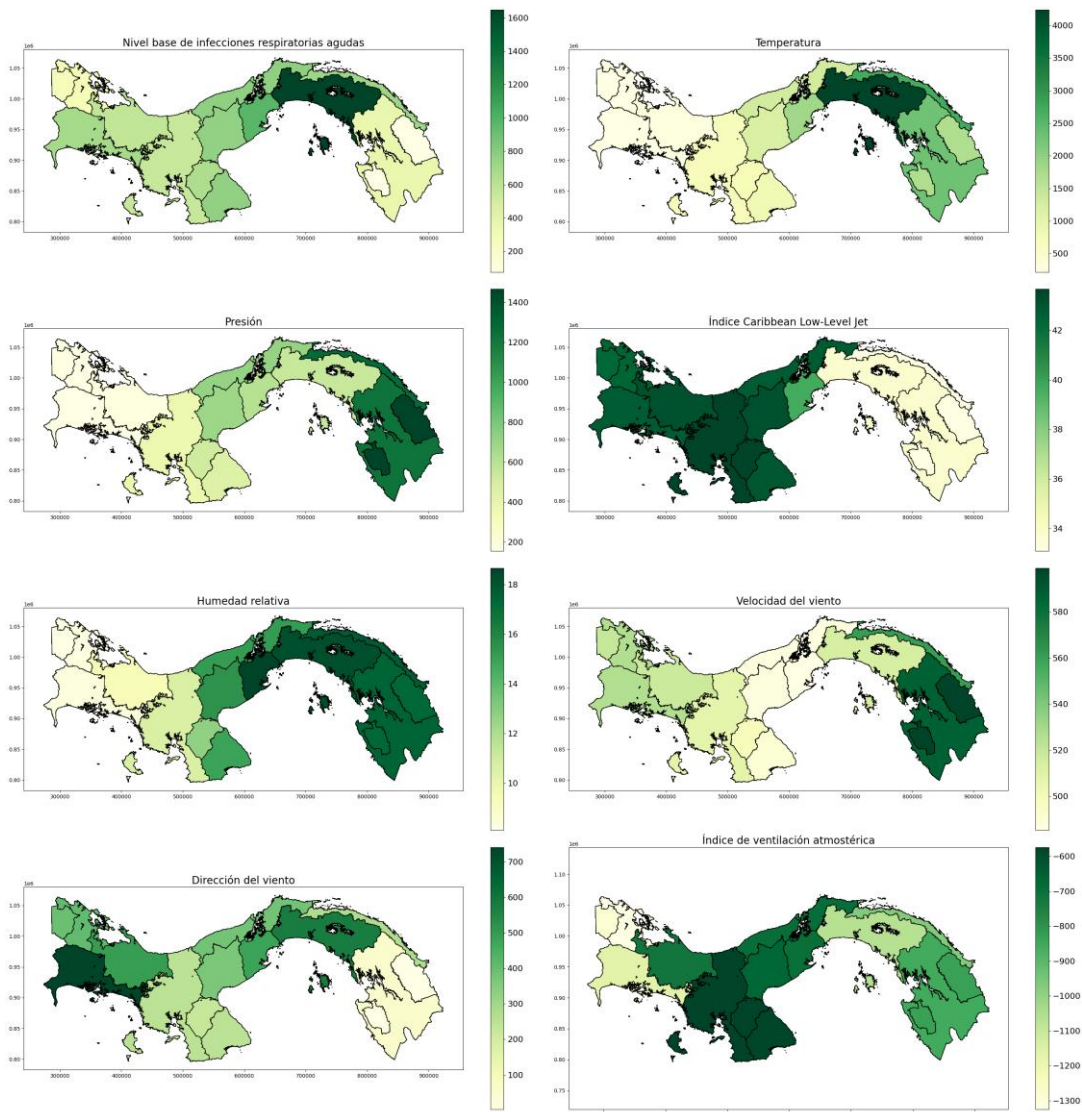


Figura 6. Distribución espacial de los coeficientes del MGWR con índice CLLJ original.

3. Regresión Geográficamente Ponderada (GWR) con índice CLLJ transformado

El modelo de Regresión Geográficamente Ponderada (GWR) se refinó mediante la transformación del índice Caribbean Low Level Jet (CLLJ), con el fin de mejorar la normalidad y la linealidad de los datos. Sin embargo, este ajuste no aumentó la capacidad explicativa frente a las versiones previas del modelo pues su coeficiente de determinación global R^2 no superó a los coeficientes de aquellas versiones.

La figura 7 revela que, tras la transformación, la intensidad de la relación viento-IRA se acentúa en las provincias del Caribe y del oriente panameño, mientras que en el centro y occidente se observan valores más

atenuados. Este patrón sugiere que las intrusiones de aire caribeño desempeñan un papel determinante en la dispersión de partículas y microorganismos que favorecen la transmisión de infecciones respiratorias agudas.

La mayor nitidez de las zonas de correlación indica que la transformación del índice CLLJ captura mejor las variaciones locales y reduce posibles sesgos estadísticos. En conjunto, el modelo respalda la hipótesis de que las fluctuaciones del CLLJ son un motor clave en la dinámica espacio-temporal de las IRAs en Panamá, reforzando la importancia de incorporar indicadores de viento ajustados en la vigilancia epidemiológica.

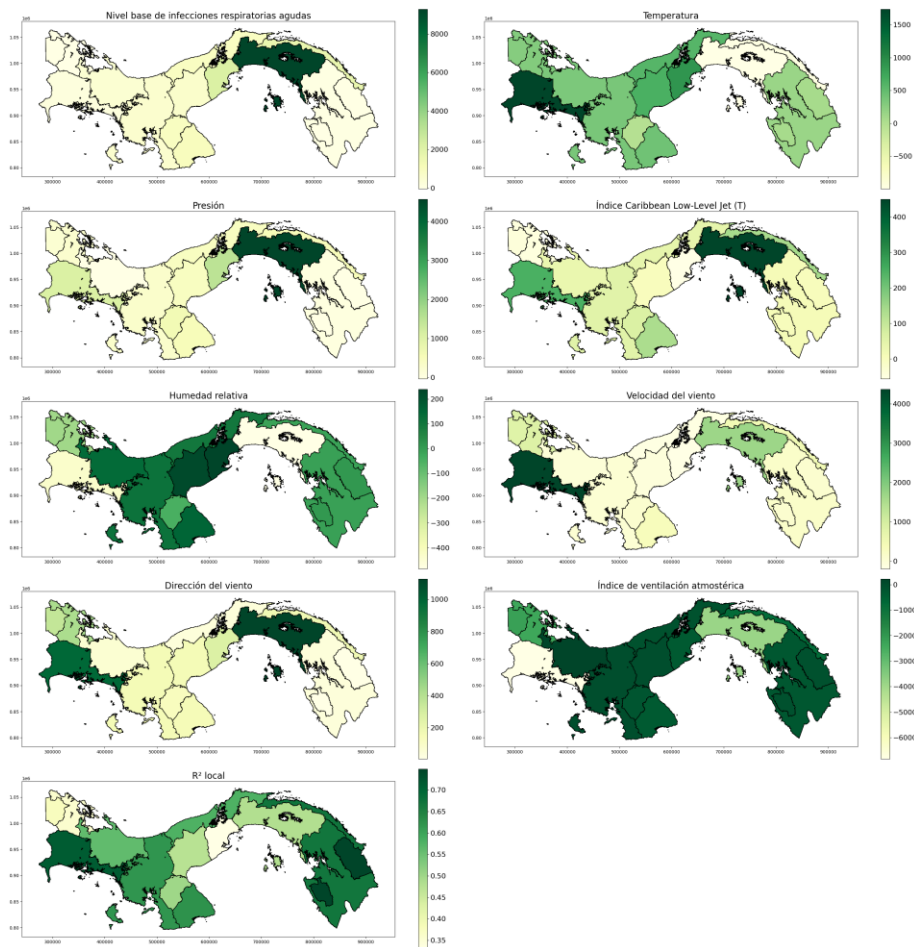


Figura 7. Distribución espacial de los coeficientes del modelo GWR con índice CLLJ transformado.

Modelos espacio-temporales no lineales

4. Modelo KhanZulfiqar

El modelo KhanZulfiqar es un modelo de aprendizaje profundo (deep learning) que incorpora interacciones no lineales y efectos espaciotemporales, lo que permite explorar relaciones complejas entre el viento y la incidencia de infecciones respiratorias agudas (IRAs) que no son capturadas por los enfoques GWR o MGWR, centrados en coeficientes localmente lineales.

En la figura 8 se aprecia que las áreas de mayor influencia del viento coinciden en gran medida con las identificadas en los modelos GWR y MGWR, lo que confirma la coherencia de los patrones espaciales previamente observados. Sin embargo, el modelo KhanZulfiqar resalta variaciones internas y transiciones graduales que sugieren procesos atmosféricos más complejos y dependientes de la interacción de múltiples variables (velocidad, dirección, ráfagas e índice CLLJ).

Además, los indicadores de ajuste —con un error cuadrático medio (ECM) reducido y valores de R^2 por provincia más elevados— confirman una ligera mejora en la capacidad predictiva en comparación con los modelos puramente espaciales. Esto indica que la inclusión explícita de no linealidades e interacciones espaciotemporales contribuye a explicar de forma más precisa la dinámica de las IRAs en Panamá.

El modelo KhanZulfiqar complementa y refuerza la evidencia obtenida con GWR y MGWR, demostrando que las fluctuaciones del Caribbean Low Level Jet y las características locales del viento son factores clave en la propagación de las IRAs, y subrayando la importancia de enfoques que integren tanto la dimensión espacial como las interacciones complejas entre variables meteorológicas.




Figura 8. Correlación provincial estimada por el modelo KhanZulfiqar.

5. Modelos Aditivos Generalizados Espaciotemporales (ST-GAM)

Para analizar la relación conjunta entre las variables de viento —velocidad, dirección, e índice Caribbean Low Level Jet (CLLJ)—, la temperatura, la humedad relativa, la presión atmosférica, ubicación y fecha, y los casos de infecciones respiratorias agudas (IRAs), se implementó un modelo ST-GAM de tipo Poisson. Este enfoque combina suavizado no lineal con dependencias espaciotemporales, lo que permite explicar de manera integral la variabilidad geográfica y temporal de las IRAs.

La figura 9 integra los efectos parciales estimados para las principales covariables. En ella se representan, junto a cada curva de influencia, los intervalos de confianza (IC) al 95 %, lo que facilita evaluar la incertidumbre de las estimaciones.

- **Variables meteorológicas:** La temperatura, la presión atmosférica, el índice Caribbean Low Level Jet (CLLJ) y la humedad relativa muestran una influencia significativa y bien delimitada, con IC 95 % estrechos en la mayor parte del rango. Se destaca el comportamiento de la temperatura, con un efecto creciente hasta alcanzar un punto de saturación, y de la presión, que presenta incrementos marcados en valores elevados.
- **Variables de viento y ventilación:** La velocidad y dirección del viento, así como el índice de ventilación atmosférica, exhiben patrones complejos de interacción espacial. Estas relaciones sugieren que la dinámica del viento no solo transporta partículas, sino que también modula su concentración, condicionando la transmisión de patógenos.
- **Patrones espacio-temporales:** El término de interacción de coordenadas (x, y) refleja la variabilidad espacial residual, mientras que los efectos de fecha y mes revelan una marcada estacionalidad, con picos que coinciden con los periodos de mayor incidencia de IRAs registrados en los datos epidemiológicos.

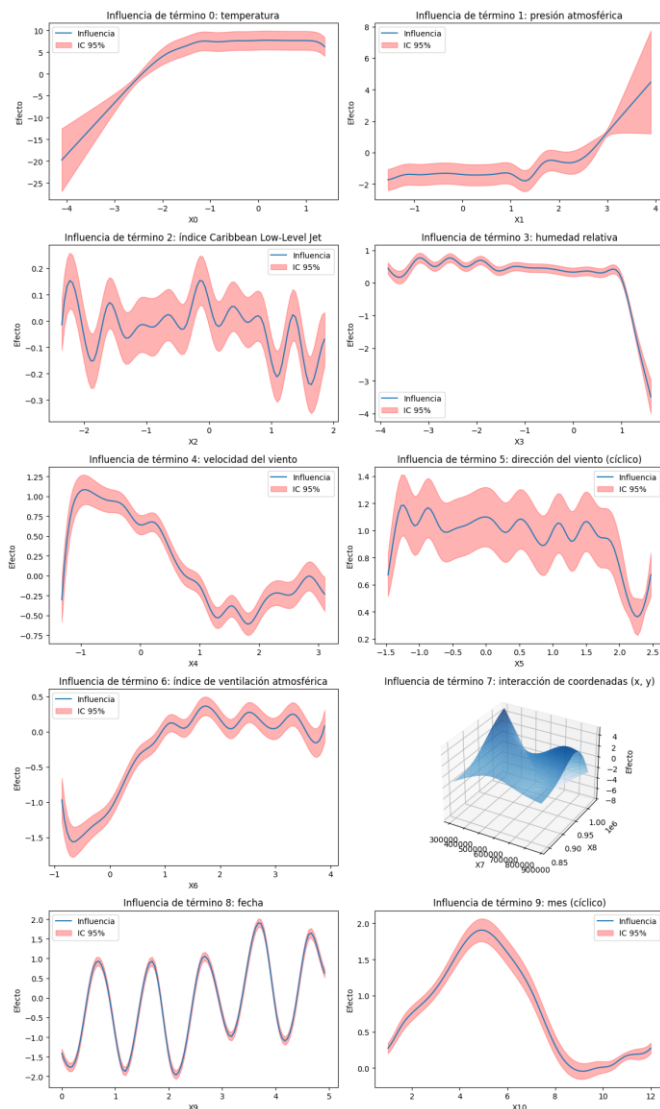


Figura 9. Influencia de variables meteorológicas, de viento y espacio-temporales en la incidencia de infecciones respiratorias agudas según el modelo ST-GAM.

El modelo alcanzó un alto poder explicativo, reflejado en métricas de ajuste favorables y en la estabilidad de los efectos a pesar de las fluctuaciones naturales de los procesos atmosféricos. En conjunto, el ST-GAM integra las dimensiones espacial y temporal con gran capacidad predictiva, válida y amplía los hallazgos de los modelos puramente espaciales (GWR, MGWR), y confirma que las variaciones del CLLJ, junto con la temperatura, la humedad y la presión, son factores determinantes en la dinámica de las infecciones respiratorias agudas en Panamá.

En la tabla 1 se muestran los parámetros de ajuste del modelo ST-GAM de tipo Poisson. En ella se reportan las variables y el grado efectivo de suavizado (EDoF: Effective Degrees of Freedom). El modelo alcanzó un Pseudo R^2 de 0.9729, evidenciando un excelente poder explicativo. No obstante, los grados de suavizado revelan que existen términos que están sobreajustados según la regla práctica de que los grados no deben superar el valor de 15. Cabe señalar que se utiliza un pseudo R^2 debido a que ST-GAM no es un modelo lineal. De manera similar al R^2 , el pseudo R^2 muestra qué tan bien explica el modelo la variabilidad de los datos. Python permite calcular automáticamente el pseudo R^2 con la fórmula de McFadden mostrada a continuación.

$$R^2_{McFadden} = 1 - \frac{\log(L_{modelo})}{\log(L_{nulo})}$$

Donde $\log(L_{modelo})$ es el logaritmo de la verosimilitud del modelo con los predictores y $\log(L_{nulo})$ es el logaritmo de la verosimilitud del modelo nulo que tiene solamente el valor del intercepto.

Tabla 1. Parámetros y significancia del modelo ST-GAM de tipo Poisson para la incidencia de infecciones respiratorias agudas en Panamá (2017-2021).

Término (s)	Descripción (variable)	Rank	EDoF
s(0)	Temperatura	20	12.7
s(1)	Presión atmosférica	20	14.0
s(2)	Índice Caribbean Low Level Jet	20	18.9
s(3)	Humedad relativa	20	16.6
s(4)	Velocidad del viento	20	18.4
s(5)	Dirección del viento (cíclica)	20	18.4
s(6)	Índice de ventilación atmosférica	20	17.5
te(7,8)	Interacción espacial (x, y)	100	15.7
s(9)	Fecha	20	15.3
s(10)	Mes (cíclico)	20	7.4
Intercepto	Constante del modelo	1	0.0

Indicadores globales del modelo

Pseudo R^2 : 0.9729 AIC: 54 095.02 AICc: 54 166.64 UBRE: 59.53

Distribución: Poisson Función de enlace: log

Para este mismo modelo se evaluaron dos configuraciones con parámetros de suavizado

automáticos y manuales, lo que permitió contrastar la robustez de los resultados.

6. Modelo ST-GAM con λ automático

En esta configuración, el modelo Aditivo Generalizado Espaciotemporal (ST-GAM) de tipo Poisson permitió que el propio algoritmo determinara el grado de suavizado (λ) óptimo para cada covariable. Esta estrategia reduce el sesgo derivado de una selección manual de parámetros y garantiza una mejor adaptación a la estructura real de los datos.

La figura 10 presenta, los efectos estimados para cada variable, junto a sus intervalos de confianza (IC) al 95 %, mientras que la tabla 2 presenta el detalle numérico de los parámetros de ajuste. El modelo alcanzó un Pseudo R^2 de 0.9731, con un AIC de 53 882.4 y un UBRE de 59.3, lo que confirma una excelente capacidad explicativa y un ajuste eficiente sin sobreparametrización.

Tabla 2. Parámetros y significancia del modelo ST-GAM con selección automática de λ

Término	Variable	λ	Rank	EDoF
s(0)	Temperatura	0.001	20	13.8
s(1)	Presión atmosférica	0.001	20	14.2
s(2)	Índice CLLJ	0.001	20	19.1
s(3)	Humedad relativa	0.001	20	18.0
s(4)	Velocidad del viento	0.001	20	19.0
s(5)	Dirección del viento (cíclico)	0.001	20	18.9
s(6)	Índice de ventilación	0.001	20	18.9
te(7,8)	Interacción espacial (x, y)	0.001	100	16.2
s(9)	Fecha	0.001	20	15.5
s(10)	Mes (cíclico)	0.001	20	7.8
Intercepto	Constante	0.001	1	1.0

Indicadores globales del modelo

Pseudo R^2 : 0.9731 AIC: 53 882.4 AICc: 53 961.0 UBRE: 59.3
Distribución: Poisson Función de enlace: log

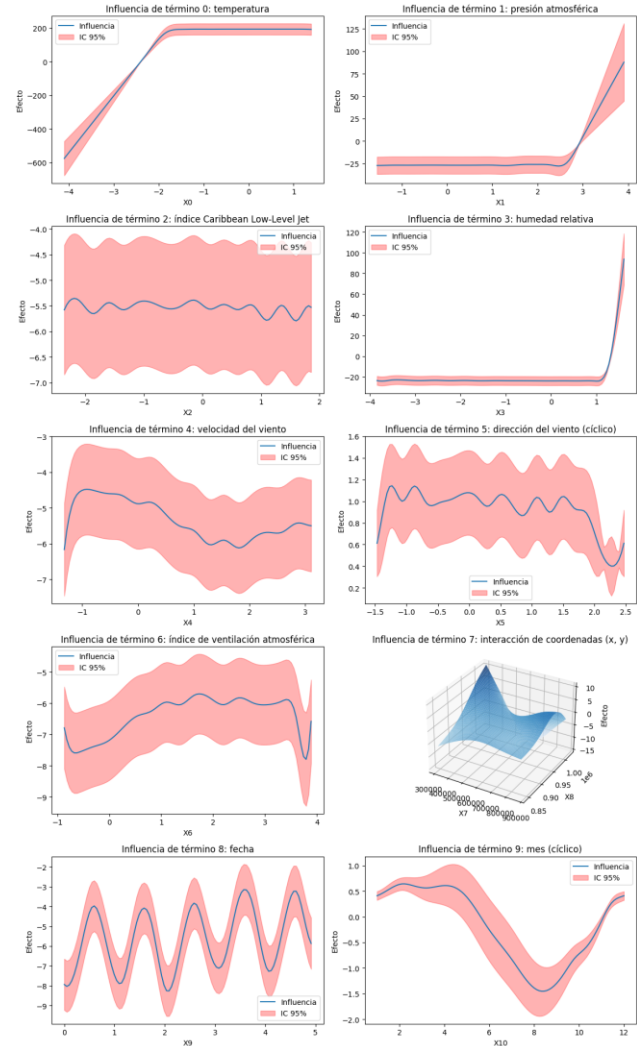


Figura 10. Influencia de variables del modelo ST-GAM con selección automática de λ .

El pseudo R^2 indica que se conserva la interpretabilidad del modelo en comparación con el modelo anterior. Se ratifica la importancia de las variables meteorológicas y los factores espacio-temporales en la predicción de las infecciones respiratorias agudas (IRAs). Entre los hallazgos más destacados:

- **Variables meteorológicas:** temperatura, presión atmosférica, índice Caribbean Low Level Jet (CLLJ) y humedad relativa presentan efectos consistentes y estadísticamente robustos.

- **Factores de viento y ventilación:** la velocidad y la dirección del viento, junto con el índice de ventilación atmosférica, continúan mostrando patrones complejos de influencia espacial.
- **Componente espacio-temporal:** la interacción de coordenadas (x, y), así como los términos de fecha y mes, capturan la estacionalidad y las fluctuaciones regionales que caracterizan la incidencia de IRAs en Panamá.

En conjunto, el ST-GAM con λ automático refuerza y valida los hallazgos obtenidos con modelo original, optimizando el proceso de calibración y mejorando la capacidad predictiva. Sin embargo, aunque se hallaron los valores óptimos del parámetro λ , se mantienen términos con grados EDoF superiores a 15, lo cual revela sobreajustes.

7. Modelo ST-GAM con λ manual

En este modelo se definieron manualmente los parámetros de suavizado (λ y rank) con el objetivo de contrastar la robustez de los resultados obtenidos en la configuración automática. Esta estrategia permite un mayor control analítico, evaluando cómo diferentes grados de suavizado influyen en la predicción de las infecciones respiratorias agudas (IRAs).

La figura 11 muestra los efectos parciales de las variables y sus intervalos de confianza (IC al 95 %), mientras que la tabla 3 resume los parámetros de ajuste. El modelo alcanzó un Pseudo R^2 de 0.9715, junto con un AIC de 56 605.8 y un UBRE de 62.5, lo que confirma una capacidad explicativa muy alta y consistente con los ajustes anteriores.

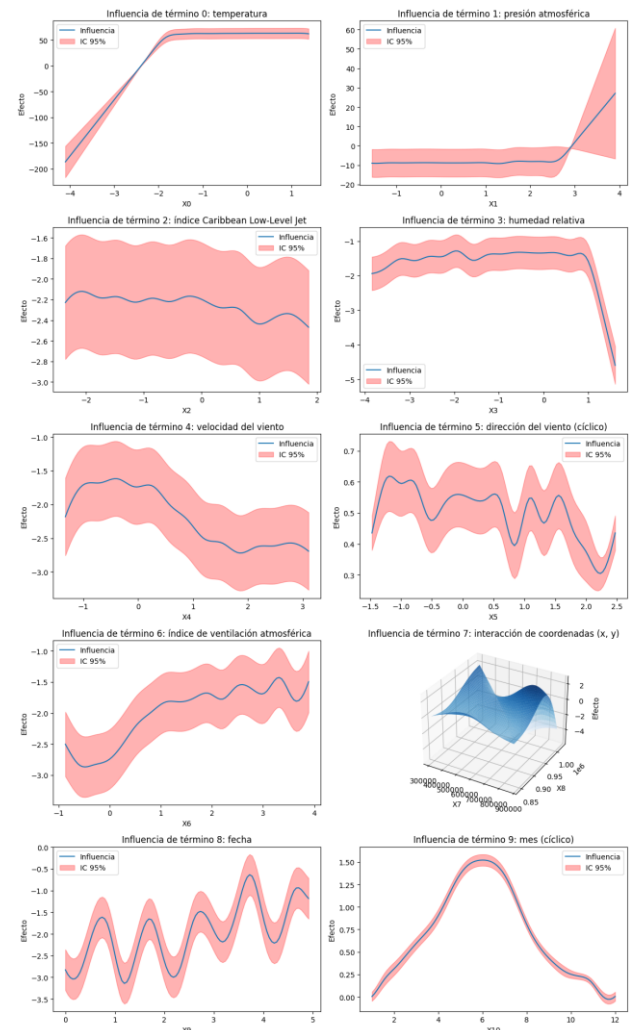


Figura 11. Influencia de variables del modelo ST-GAM con selección manual de λ .

Tabla 3. Parámetros y significancia del modelo ST-GAM con selección manual de λ

Término	Variable	λ	Rank	EDoF
s(0)	Temperatura	0.004	20	13.5
s(1)	Presión atmosférica	0.004	20	14.1
s(2)	Índice CLLJ	90	17	14.3
s(3)	Humedad relativa	20	20	15.0
s(4)	Velocidad del viento	65	17	13.1
s(5)	Dirección del viento (cíclico)	90	17	13.7
s(6)	Índice de ventilación	12	20	14.6
te(7,8)	Interacción espacial (x, y)	10	100	14.8
s(9)	Fecha	10	20	13.2
s(10)	Mes (cíclico)	0.004	20	5.2
Intercepto	Constante	0.004	1	1.0

Indicadores globales del modelo
Pseudo R²: **0.9715** AIC: **56 605.8** AICc: **56 655.9** UBRE: **62.5**
Distribución: **Poisson** Función de enlace: **log**

Todos los términos de suavizado quedaron sin sobreajuste (EDoF < 15), y la conservación del pseudo R² cercano a 0.97 obtenido anteriormente ratificó la interpretabilidad del modelo así como la importancia de las variables meteorológicas y los factores espacio-temporales. Entre los hallazgos destacan:

- **Variables meteorológicas:** temperatura, presión atmosférica, índice Caribbean Low Level Jet (CLLJ) y humedad relativa mantienen patrones similares a los observados con el modelo de λ automático.
- **Factores de viento y ventilación:** velocidad y dirección del viento, así como el índice de ventilación atmosférica, conservan su influencia significativa.
- **Componente espacio-temporal:** los términos de interacción de coordenadas (x, y), fecha y mes reafirman la marcada estacionalidad de los casos de IRAs.

La comparación entre el ST-GAM con λ automático y el ST-GAM con λ manual demuestra la robustez de los resultados, evidenciando que las variaciones del viento, especialmente las asociadas al índice CLLJ, se correlacionan de manera significativa con la dinámica temporal de las IRAs. En ambos enfoques, la integración de las dimensiones espacial y temporal mejora la capacidad predictiva en relación con los modelos puramente espaciales y lineales.

La tabla 4 evidencia que los modelos ST-GAM, especialmente la versión con λ automático, alcanzan los menores errores cuadráticos medios y los mayores valores de R² global.

Tabla 4. Métricas comparativas de los modelos de predicción de IRAs

Modelo	Error cuadrático medio (ECM)	R ² global
GWR con índice CLLJ original	1 454 325.12	0.6981
MGWR con índice CLLJ original	2 557 451.02	0.4691
GWR con índice CLLJ transformado	1 456 822.43	0.6976
KhanZulfiqar	0.4429	0.6086
ST-GAM	94 386.07	0.9729
ST-GAM con λ automático	93 780.20	0.9731
ST-GAM con λ manual	97 836.21	0.9722

Esto confirma que la integración conjunta de variables de viento, factores meteorológicos y componentes espacio-temporales proporciona una capacidad de predicción claramente superior a la de los enfoques puramente espaciales (GWR, MGWR) o a los que no modelan de forma integral las interacciones no lineales (KhanZulfiqar).

Discusión

3.3. Interpretación general de los hallazgos

Los resultados obtenidos mediante los diferentes enfoques de modelado espacial y espacio-temporal proporcionan evidencia robusta de la relación entre los patrones de viento y la incidencia de infecciones respiratorias agudas (IRAs) en Panamá. La consistencia observada entre los modelos GWR, MGWR, KhanZulfiqar y ST-GAM fortalece la validez de los hallazgos y sugiere que esta asociación es tanto estadísticamente significativa como geográficamente relevante. Ello coincide con estudios que vinculan la circulación de vientos de bajo nivel con el transporte de aerosoles y agentes patógenos en regiones tropicales [46], [47].

3.4. Heterogeneidad espacial de la relación viento–IRA

Los modelos de regresión geográficamente ponderada (GWR/MGWR) muestran una heterogeneidad espacial marcada: la fuerza de asociación varía por provincia, con correlaciones locales más altas en zonas más expuestas a las corrientes del Caribe. Esta variabilidad puede explicarse por:

- Topografía y microclimas derivados de las cordilleras y valles, que modulan el transporte atmosférico local [48].
- Densidad poblacional y urbanización, donde islas de calor y rugosidad urbana favorecen la persistencia y dispersión de aerosoles [49], [50].
- Proximidad a fuentes de humedad y brisas costeras, que interactúan con patrones sinópticos y modifican la dispersión de patógenos [51].

3.5. Papel del Caribbean Low-Level Jet (CLLJ)

La mejora al incorporar el CLLJ transformado subraya su rol en la dinámica de las IRAs. El CLLJ es un mecanismo de transporte de gran escala que moviliza humedad, aerosoles y posibles microorganismos desde el Caribe hacia Centroamérica [47], [52], pudiendo introducir agentes en poblaciones no expuestas o modificar condiciones ambientales que favorezcan patógenos endémicos [53]. Además, el CLLJ modula la estabilidad atmosférica y los procesos de mezcla en la capa límite; episodios intensos pueden favorecer acumulación de aerosoles cerca de la superficie [10], [54].

3.6. Patrones temporales y estacionalidad

El ST-GAM detecta patrones estacionales coherentes con los periodos de mayor incidencia de IRAs, reforzando la hipótesis de que las variaciones del viento, junto con humedad y temperatura, actúan como desencadenantes/amplificadores de brotes [55]. Esta estacionalidad sincroniza con la variabilidad conocida del CLLJ, más intenso en el verano boreal (junio-agosto) [46], y confirma que el viento no actúa aislado: temperatura y presión muestran efectos parciales significativos que evidencian interacciones multivariadas [56].

3.7. Robustez metodológica y complementariedad

La convergencia entre GWR/MGWR, KhanZulfiqar (no linealidades e interacciones complejas) y ST-GAM (dinámica espacio-temporal) refuerza la confiabilidad de los resultados [57]. La comparación entre suavizado automático y manual en ST-GAM muestra estabilidad frente a especificaciones técnicas, aumentando la confianza en las conclusiones. Sobresale el hecho de que

los modelos ST-GAM mantuvieron siempre el pseudo R^2 por encima de 0.97 a pesar de los cambios realizados para eliminar el sobreajuste. Esto suministra confiabilidad en las interpretaciones obtenidas con base en los modelos ST-GAM.

3.8. Rol del panel de visualización

El dashboard de Power BI valida y democratiza los hallazgos estadísticos al permitir explorar correlaciones y proyecciones en tiempo real mediante filtros, mapas y tendencias. Es un recurso operativo para planificación sanitaria y comunicación de riesgos, fortaleciendo la respuesta ante incrementos de casos. Puede tener las siguientes implicaciones para la salud pública:

- **Alertas tempranas:** la capacidad predictiva habilita sistemas basados en pronósticos meteorológicos, especialmente del CLLJ [58].
- **Asignación geográfica de recursos:** priorización de provincias con mayor susceptibilidad para atención respiratoria y campañas focalizadas [59].
- **Enfoques integrales:** integrar factores meteorológicos con determinantes sociales/ambientales para intervenciones más efectivas [60].

El panel de visualización incluye los pronósticos realizados con el modelo KhanZulfiqar para los últimos 4 meses de 2021. Algunos de los resultados se muestran por provincia en la figura 12. Destaca el hecho de que los valores pronosticados de casos de IRA son muy cercanos a los valores reales, excepto para las provincias de Panamá y Panamá Oeste.




Figura 12. Comparación de valores pronosticados y valores reales de casos de IRA según el modelo KhanZulfiqar.

En cuanto a la evaluación del impacto económico de los casos de IRA, en el panel de visualización se incluye una página que presenta la tabla de medianas de salario por provincia así como la estimación del costo de una incapacidad por hora. Se calcula el costo de una incapacidad de 2 jornadas laborales que equivalen a 16 horas. En los mapas se muestra el valor proporcional de las incapacidades por provincia, con base tanto en el valor real como en el valor pronosticado por el modelo KhanZulfiqar. En ambas situaciones, la provincia mayormente afectada es la de Panamá, y le siguen las provincias de Panamá Oeste y Chiriquí. Esto coincide con el hecho de que son las provincias con mayor población y con las mayores medianas de salario.

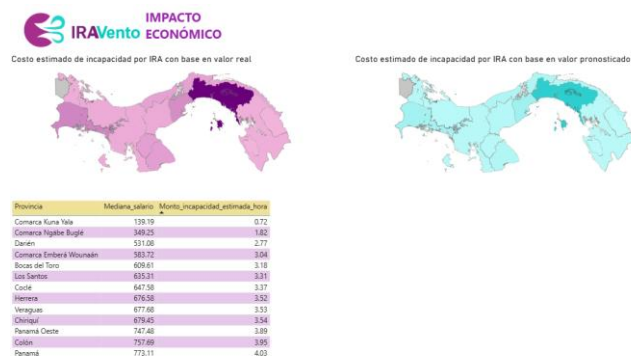


Figura 13. Comparación del impacto económico provocado por los casos de IRA con base en valores reales y valores reales.

4. CONCLUSIONES

Este estudio demuestra con evidencia robusta que los patrones de viento, especialmente la intensidad y dirección asociadas al Caribbean Low-Level Jet (CLLJ), están significativamente relacionados con la incidencia de infecciones respiratorias agudas (IRAs) en Panamá. La convergencia de resultados obtenidos mediante enfoques de regresión espacial (GWR, MGWR y KhanZulfiqar) y de modelado espacio-temporal (ST-GAM en configuraciones automática y manual) confirma la validez y relevancia de la propuesta. La incorporación de variables de viento, humedad, temperatura y ventilación atmosférica fortaleció la capacidad explicativa de los modelos y permitió caracterizar patrones espaciales y estacionales coherentes con la climatología regional.

Entre las principales contribuciones del trabajo destacan:

- El diseño de un marco metodológico integrador, que combina análisis espacial y espacio-temporal con un panel de visualización en Power BI para la exploración interactiva de resultados.
- La identificación de áreas y períodos de mayor riesgo de IRAs asociados a variaciones en el CLLJ, lo cual constituye un insumo valioso para la vigilancia epidemiológica y la planificación sanitaria.
- La demostración de que la incorporación de pronósticos meteorológicos puede mejorar los sistemas de alerta temprana y optimizar la asignación geográfica de recursos de salud.

En cuanto a limitaciones, se reconoce que la resolución espacial y temporal de los datos meteorológicos y epidemiológicos podría no capturar variabilidad de pequeña escala, y que factores no observados —como calidad del aire, patrones de movilidad, ventilación de interiores o condiciones socioeconómicas— pueden actuar como confusores. Además, la naturaleza

observacional del estudio restringe la posibilidad de establecer relaciones causales definitivas.

Estas consideraciones abren líneas de investigación futura, entre ellas:

- Incorporar datos de mayor resolución o agrupados con frecuencia menor a mensual y emplear otros algoritmos de aprendizaje profundo para mejorar la predicción de brotes.
- Analizar episodios meteorológicos extremos para identificar umbrales críticos de riesgo.
- Profundizar en los mecanismos biológicos de transporte y supervivencia de patógenos bajo distintos regímenes de viento.
- Replicar el enfoque en otras regiones tropicales y subtropicales, a fin de validar y generalizar los hallazgos.

En términos de impacto científico y social, los resultados constituyen una contribución relevante a la climatología de la salud al integrar meteorología y epidemiología con herramientas de análisis de datos y visualización. La metodología propuesta ofrece referencia directa para estudios en entornos tropicales, apoya la formulación de políticas de salud pública basadas en evidencia y sirve de modelo para el desarrollo de sistemas predictivos operacionales, fortaleciendo la capacidad de respuesta ante brotes respiratorios en Panamá y en otras regiones con condiciones climáticas comparables.

En términos económicos, los casos de IRA tienen un efecto importante en las provincias con alta concentración de actividades económicas relevantes para el país, como son los servicios, el comercio y la agricultura. El efecto no se limita solo al ausentismo causado por las infecciones respiratorias agudas sino a la afectación en productividad y costos que sufren los distintos sectores económicos donde laboran las personas enfermas.

AGRADECIMIENTOS

Al Dr. Grimaldo Ureña por su orientación.

CONFLICTO DE INTERESES

Los autores declaran no tener conflicto de intereses.

CONTRIBUCIÓN Y APROBACIÓN DE LOS AUTORES

F. M. se encargó de la investigación, análisis de datos, redacción y preparación del borrador original.

L. M. se encargó de la metodología, análisis de datos y desarrollo de modelos.

S.R. se encargó de la investigación, conceptualización y análisis de datos.

A. M. se encargó del preprocesamiento de datos, análisis de datos y visualización de datos.

J. C. se encargó de la supervisión, validación, redacción y edición.

Todos los autores afirmamos que hemos leído y aprobado la versión final de este artículo.

REFERENCIAS

- [1] M. Baldini y A. Stevens, «Dry wind events in the Mediterranean basin: Definition, climatology, and impacts,» *Int. J. Climatol*, vol. 41, n° 5, pp. 3145-3160, 021.
- [2] N. Carlson y J. Prospero, «The Saharan Air Layer over the tropical North Atlantic: Structure and properties,» *Mon. Weather Rev*, vol. 99, n° 7, pp. 505-531, 1972.
- [3] A. Evan, «The role of the Saharan Air Layer in Atlantic climate variability,» *Nat. Geosci.*, vol. 9, pp. 113-116, 2016.
- [4] R. Amador, «The Intra-Americas Low-Level Jet: Structure, variability, and climate significance,» *J. Climate*, vol. 25, pp. 1265-1280, 2012.
- [5] D. Wang, «Indoor relative humidity and its associations with health: A review of epidemiological and experimental evidence,» *Sci. Total Environ*, vol. 872, p. 162138, 2023.
- [6] E. Kudo, L. Yockey, L. Yockey y A. Iwasaki, «Low ambient humidity impairs barrier function and innate resistance against

influenza infection,» PNAS Proc. Natl. Acad. Sci. USA, vol. 116, nº 22, p. 10905–10910, 2019.

[7] T. Mäkinen, R. Juvonen, J. Jokelainen, T. Harju, A. Peitso, A. Bloigu, S. Silvennoinen-Kassinen, M. Leinonen y J. Hassi, «Cold temperature and low humidity are associated with increased occurrence of respiratory tract infections,» *Respir. Med.*, vol. 103, nº 3, pp. 456–462, 2009.

[8] M. Díaz, «Health impacts of Saharan dust exposure: A systematic review,» *Environ. Res.*, vol. 234, p. 1152, 2024.

[9] H. Marrero-Ortiz, «Temperature and humidity affect virus survival and transmission: Modeling evidence,» *Sci. Rep.*, vol. 12, p. 13756, 2022.

[10] K. H. Cook and E. K. Vizzy, «Hydrodynamics of the Caribbean Low-Level Jet and its relationship to precipitation,» *Journal of Climate*, vol. 23, no. 6, pp. 1477–1494, 2010.

[11] S. A. Ordóñez-Zúñiga, M. Correa-Ramírez, C. Ricaurte-Villota y M. B. Salamanca, «The Panama Low-Level Jet: extension, annual cycle and modes of variation,» *Latin American Journal of Aquatic Research*, vol. 49, nº 5, pp. 750–762, 2021.

[12] A. Jury, «Diurnal variation of the Caribbean boundary layer and its relation to regional meteorology,» *Theor. Appl. Climatol.*, vol. 145, nº 3, p. 913–926, 2021.

[13] Organización Mundial de la Salud, «Las nuevas Directrices mundiales de la OMS sobre la calidad del aire tienen como objetivo evitar millones de muertes debidas a la contaminación del aire,» Comunicado de prensa, Copenhague y Ginebra, 2021.

[14] S. Park, «Wind-induced resuspension of particles and implications for air quality,» *Atmos.*, vol. 10, nº 4, pp. 1231–1242, 2019.

[15] O. Bar-Or, I. Neuman y R. Dotan, «Effects of dry and humid climates on exercise-induced asthma in children and preadolescents,» *Journal of Allergy and Clinical Immunology*, vol. 60, nº 3, pp. 163–168, 1977.

[16] H. Wen, S. Wang, C. Wu y L. Mao-Chang, «Association of Asian dust storms and PM_{2.5} with clinical visits for respiratory diseases in children,» *Atmospheric Environment*, vol. 333, 2024.

[17] K. Monte, A. Costa, H. Morais, N. Guedes, C. Silva, J. Neto, J. Ferreira, T. Cavalcante y R. Moreira, «Decreased childhood asthma hospitalizations linked to hotter, drier climate with lower wind speed

in drylands,» *International Journal of Environmental Health Research.*, pp. 1–13, 2025.

[18] J. Lohi, T. Tuomela y T. Tuuminen, «Exposure to Mould and Moisture Damage Is a Potential Risk Factor for the Development of Respiratory Diseases Opinion,» *International Journal of Immunology*, vol. 8, nº 3, pp. 11–16, 2020.

[19] D. Edwards y K. Chung, «Mouth breathing, dry air, and low water permeation promote inflammation, and activate neural pathways, by osmotic stresses acting on airway lining mucus,» *QRB Discovery*, vol. 4, nº 1, 2023.

[20] J. Seok, B. Lee y H. Yoon, «Association between humidity and respiratory health: the 2016–2018 Korea National Health and Nutrition Examination Survey,» *Respiratory Research*, vol. 25, nº 1, pp. 1–12, 2024.

[21] A. Prospero, «African dust events and asthma admissions in Trinidad and Tobago,» *Environ. Health Perspect.*, vol. 114, nº 9, p. 1367–1372, 2006.

[22] J. Samoli, «Saharan dust events and respiratory hospital admissions in Guadeloupe,» *PLoS One*, vol. 10, nº 3, p. 1200, 2015.

[23] R. George, «Impact of Saharan dust and humidity on asthma in Grenada,» *Caribbean Med. J.*, vol. 59, nº 2, pp. 78–85, 2017.

[24] A. Rivera-Ramírez, «African dust intrusions and COPD exacerbations in Miami,» *Chest*, vol. 160, nº 3, pp. 1012–1021, 2021.

[25] J. Ortega-García, I. Martínez-Hernández, A. Cárcelos-Álvarez, C. Solano-Navarro, R. Ramis, E. Aguilar-Ros, M. Sánchez-Solis y F. López-Hernández, «Contaminación atmosférica urbana e ingresos hospitalarios por asma y enfermedades respiratorias agudas en la ciudad de Murcia (España),» *Anales de Pediatría*, vol. 93, nº 2, pp. 95–102, 2020.

[26] D. Benítez Aldaz y J. Ordóñez Zavala, «Generación de un modelo espacial de riesgo de enfermedades respiratorias crónicas a partir de datos de calidad de aire en la ciudad de Quito entre los años 2013 a 2017,» *Repositorio Institucional de la Universidad Politécnica Salesiana*, Quito, 2019.

[27] M. Méndez, «Modelo de predicción para identificar la gravedad de una enfermedad de respiración aguda (ERA) para las personas de Bogotá relacionados con el agente contaminante PM_{2.5} y otros factores ambientales,» Bogotá, 2025.

- [28] J. Zúñiga, M. Tarajia, V. Herrera, W. Urriola, B. Gómez y J. Motta, «Assessment of the Possible Association of Air Pollutants PM10, O3, NO2 With an Increase in Cardiovascular, Respiratory, and Diabetes Mortality in Panama City: A 2003 to 2013 Data Analysis.», *Medicine* (Baltimore), vol. 95, n° 2, 2016.
- [29] A. Romaszko-Wojtowicz, E. Dragańska, A. Doboszyńska et al., “Impact of seasonal biometeorological conditions and particulate matter on asthma and COPD hospital admissions,” *Scientific Reports*, vol. 15, p. 450, 2025. doi: 10.1038/s41598-024-84739-9.
- [30] D. Boura, M. Spanakis, G. Markakis, G. Notas, C. Lionis, N. Tzanakis, and E. Paraskakis, “Exploring the relationship between wind patterns and hospital admissions due to respiratory symptoms in children,” *Children*, vol. 11, no. 6, p. 717, 2024. doi: 10.3390/children11060717.
- [31] Y. Lu, D. Niu, S. Zhang, and L. Zhang, “Ventilation indices for evaluation of airborne infection risk control performance of air distribution,” *Building and Environment*, vol. 225, art. no. 109440, 2022. doi: 10.1016/j.buildenv.2022.109440.
- [32] H. Cai, J. Huang, M. Jin, Z. Ai, H. Liu, and L. Ye, “Influence of air pollution and wind chill on hospital admissions for COPD exacerbation in Fengxian District, Shanghai,” *International Journal of Clinical and Experimental Medicine*, vol. 11, no. 9, pp. 9974–9980, 2018.
- [33] W. Guo, L. Yi, P. Wang, B. Wang, and M. Li, “Assessing the effects of meteorological factors on daily children’s respiratory disease hospitalizations: A retrospective study,” *Heliyon*, vol. 6, no. 8, p. e04657, 2020. doi: 10.1016/j.heliyon.2020.e04657.
- [34] Instituto Nacional de Estadística y Censo (INEC), Casos reportados de enfermedades respiratorias en la República, según tipo, provincia y comarca indígena: Años 2015-2019, Panamá: INEC, 2021. [Online]. Available: <https://www.inec.gob.pa/archivos/P07055475202104151140176.pdf>
- [35] Ministerio de Salud de la República de Panamá, Anuario Estadístico del 2022, Panamá: MINSA, 2022. [Online]. Available: <https://www.minsa.gob.pa/contenido/anuario-estadistico-del-2022>.
- [36] H. Hersbach et al., “ERA5 monthly averaged data on single levels from 1940 to present,” Copernicus Climate Change Service (C3S), Climate Data Store (CDS), 2023. [Online]. Available: <https://doi.org/10.24381/cds.fl7050d7>.
- [37] H. Hersbach et al., “ERA5 monthly averaged data on pressure levels from 1940 to present,” Copernicus Climate Change Service (C3S), Climate Data Store (CDS), 2023. [Online]. Available: <https://doi.org/10.24381/cds.6860a573>.
- [38] Fotheringham, A. S., et al. "Exploring Spatial Context: A Comprehensive Bibliography of GWR and MGWR." *arXiv preprint*, 2024. doi: 10.48550/arxiv.2404.16209
- [39] Maiti, A., et al. "Spatiotemporal effects of the causal factors on COVID-19 incidences in the contiguous United States." *Sustainable Cities and Society*, 2021. doi: 10.1016/J.SCS.2021.102784
- [40] Oshan, T. M., et al. "MGWR: A Python Implementation of Multiscale Geographically Weighted Regression." *Journal of Open Source Software*, 2019. doi: 10.21105/joss.01928
- [41] Zhang, C., et al. "Exploring the spatiotemporal effects of meteorological factors on hand, foot and mouth disease." *BMC Public Health*, 2024. doi: 10.1186/s12889-024-20596-5
- [42] Khan, M., Zulfiqar, A. "Spatial and temporal epidemiological analysis in infectious disease surveillance." *Spatial Statistics*, 2023.
- [43] Comber, A. "stgam: Spatially and Temporally Varying Coefficient Models Using Generalized Additive Models." *CRAN package*, 2024. doi: 10.32614/cran.package.stgam
- [44] Wood, S. N. "Generalized Additive Models: An Introduction with R." *Chapman and Hall/CRC*, 2017.
- [45] Comber, A., et al. "Encapsulating Spatially Varying Relationships with a Generalized Additive Model." *Preprint*, 2024. doi: 10.20944/preprints202411.0375.v1
- [46] J. A. Amador, “The intra-Americas sea low-level jet: Overview and future research,” *Annals of the New York Academy of Sciences*, vol. 1146, no. 1, pp. 153-188, 2008.
- [47] C. Wang, “Variability of the Caribbean Low-Level Jet and its relations to climate,” *Climate Dynamics*, vol. 29, no. 4, pp. 411-422, 2007.
- [48] G. Poveda and O. J. Mesa, “On the existence of Lloró (the rainiest locality on Earth): Enhanced ocean–land–atmosphere interaction by a low-level jet,” *Geophysical Research Letters*, vol. 27, no. 11, pp. 1675–1678, 2000.

[49] R. Tellier, “Review of aerosol transmission of influenza A virus,” *Emerging Infectious Diseases*, vol. 12, no. 11, pp. 1657–1662, 2006.

[50] X. Xie, Y. Li, A. T. Chwang, P. L. Ho, and W. H. Seto, “How far droplets can move in indoor environments—revisiting the Wells evaporation–falling curve,” *Indoor Air*, vol. 17, no. 3, pp. 211–225, 2007.

[51] S. T. Miller, B. D. Keim, R. W. Talbot, and H. Mao, “Sea breeze: structure, forecasting, and impacts,” *Reviews of Geophysics*, vol. 41, no. 3, p. 1011, 2003.

[52] D. W. Griffin, “Atmospheric movement of microorganisms in clouds of desert dust and implications for human health,” *Clinical Microbiology Reviews*, vol. 20, no. 3, pp. 459–477, 2007.

[53] J. K. Brown and M. S. Hovmöller, “Aerial dispersal of pathogens on the global and continental scales and its impact on plant disease,” *Science*, vol. 297, no. 5581, pp. 537–541, 2002.

[54] R. B. Stull, *An Introduction to Boundary Layer Meteorology*, vol. 13. Springer, 1988.

[55] J. Shaman and M. Kohn, “Absolute humidity modulates influenza survival, transmission, and seasonality,” *Proceedings of the National Academy of Sciences of the United States of America*, vol. 106, no. 9, pp. 3243–3248, 2009.

[56] A. C. Lowen and J. Steel, “Roles of humidity and temperature in shaping influenza seasonality,” *Journal of Virology*, vol. 88, no. 14, pp. 7692–7695, 2014.

[57] A. S. Fotheringham, C. Brunson, and M. Charlton, *Geographically Weighted Regression: The Analysis of Spatially Varying Relationships*. John Wiley & Sons, 2003.

[58] J. Shaman and A. Karspeck, “Forecasting seasonal outbreaks of influenza,” *Proceedings of the National Academy of Sciences*, vol. 109, no. 50, pp. 20425–20430, 2012.

[59] C. Viboud, W. J. Alonso, and L. Simonsen, “Influenza in tropical regions,” *PLoS Medicine*, vol. 3, no. 4, e89, 2006.

[60] M. Marmot and R. Wilkinson (eds.), *Social Determinants of Health*. Oxford University Press, 2005.

Este apartado no es obligatorio. Se usa para incluir cualquier tipo de material importante para justificar los resultados del trabajo, pero que no pueda presentarse en el desarrollo continuo del artículo.

Número ORCID ID:

0000-0002-4681-9471 Fabiola M. Montero-González

0009-0003-1265-364X Luis A. Muñoz-Morales

0009-0004-3796-9453 Samuel A. Rodríguez-Rodríguez

0009-0000-0197-5799 Antonio Melillo-Acevedo

ANEXOS